



Data Analysis Presentation

Bondeh Essomba Ryann Loic

ghofrane ben amor

Gibert Clément

Nguekeu Arthur

Raian Dary KAMMI LEUGA

Pharex Aubin PANMO YONGUI



DataOps vs DevOps

DevOps

Méthodologie qui unit le développement logiciel (Dev) et les opérations IT (Ops) pour accélérer et fiabiliser la livraison d'applications.

Objectif : Éliminer les silos entre développeurs et équipes opérationnelles, automatiser le cycle de vie logiciel.

Cycle : Planifier → Développer → Construire → Tester → Déployer → Opérer → Surveiller

DataOps

Méthodologie qui applique les principes DevOps au domaine de l'analytique et de la gestion des données.

Objectif : Améliorer la qualité, la vitesse et la fiabilité des analyses de données en brisant les silos entre producteurs et consommateurs de données.

Cycle : Planifier → Développer → Intégrer → Tester → Déployer → Opérer → Surveiller les pipelines de données



Points Communs

1

Méthodologie Agile et itérative

2

Automatisation (CI/CD)

3

Élimination des silos organisationnels

4

Monitoring et feedback continu

5

Versioning (code ou données)

Différences Clés

Critère	DevOps	DataOps
Focus	Applications et logiciels	Données et analytics
Livrable	Fonctionnalités, updates	Insights, dashboards, modèles ML
Équipes	Développeurs + Ops IT	Data Engineers + Data Scientists + Analysts
Métrique clé	Time-to-market, uptime	Time-to-insight, qualité des données
Outils	Jenkins, Docker, Kubernetes	Airflow, Kafka, dbt, Snowflake, Databricks
Complexité	Code stable	Données changeantes (schéma, qualité)



Exemple Netflix


DevOps : Déploiement de nouvelles fonctionnalités de l'application (interface, lecteur vidéo)

DataOps : Système de recommandation alimenté par l'analyse de milliards de données utilisateur en temps réel




Point clés

- DevOps = Software / DataOps = Data
- Les deux visent rapidité, qualité et collaboration
- DataOps s'inspire de DevOps mais adapté aux défis data
- Complémentaires, pas concurrents



Exemples et Points clés

Carte Mentale




Snowflake

Databricks




Architecture Snowflake : L'Hybride Innovant

Snowflake combine le meilleur des architectures de bases de données à disque partagé et sans rien partagé. Il utilise un dépôt centralisé pour la persistance des données et des clusters MPP pour le traitement des requêtes.



Architecture Databricks : Le Lakehouse

Databricks implémente une architecture "lakehouse", combinant un data lake (fichiers Parquet/Delta Lake) avec des fonctionnalités d'entrepôt de données. Les données sont centralisées sur le stockage objet cloud.



Snowflake vs Databricks : Comparaison

Critère	Snowflake	Databricks
Type de plateforme	Entrepôt de données cloud managé, orienté SQL et analytics	Lakehouse big data & AI (data lake + warehouse unifiés)
Cas d'usage "idéaux"	Entrepôt analytique central, dashboards temps quasi réel, partage de données externes	Entrepôt de données cloud managé, orienté SQL et analytics
Architecture	3 couches : stockage, compute (virtual warehouses), services cloud (métadonnées, sécurité)	Data lake (Delta Lake) + clusters Spark/SQL + catalogue unifié (Unity Catalog)
Domaine d'application majeur	BI, reporting, analytics SQL, data sharing entre équipes/partenaires	ETL/ELT avancé, big data, streaming, data science, ML/AI de bout en bout
Type de données ciblé	Principalement données structurées et semi-structurées pour l'analytique	Structurées, semi-structurées et non structurées pour traitement et ML
Public cible	Data analysts, équipes BI, métiers orientés SQL	Data engineers, data scientists, ML/AI engineers

Avantages snowflake et Databricks

Critère

Snowflake – Avantages

Databricks – Avantages

Architecture

Architecture simple à 3 couches (stockage / compute / services), entièrement managée.

Lakehouse unifié : data lake + warehouse + ML sur la même plateforme.

Domaine d'application / workloads

Excellente plateforme pour BI, reporting, requêtes SQL analytiques et data sharing.

Très adapté au big data, ETL/ELT lourds, streaming, data science et ML/AI de bout en bout

Performance & scalabilité

Élasticité quasi instantanée via les virtual warehouses, bonne concurrence sur les requêtes BI

Très bonne performance sur workloads distribués (Spark) et volumes massifs

Coût & modèle de facturation

Modèle pay-as-you-go clair (stockage + compute séparés), peu d'overhead d'admin.

Peut être très compétitif en coût pour gros volumes et usages combinés data + ML.

Simplicité d'utilisation

Interface SQL et admin très accessible aux équipes BI / métier.

Grande flexibilité pour les data engineers et data scientists (notebooks, Spark, MLflow).

Métiers de la data

Métier	Rôle	Missions clés	Compétences clés
Data Engineer	Conçoit, construit et maintient les architectures et pipelines de données ; assure la disponibilité, la qualité et la performance des systèmes.	- Collecte & ingestion des données (pipelines, ETL)- Structuration, nettoyage et transformation- Gestion des bases de données & data lakes- Automatisation des flux & monitoring- Mise en production, maintenance des systèmes	- Python, SQL, Java/Scala- Hadoop, Spark, Kafka- Bases SQL/NoSQL- Cloud (AWS, GCP, Azure)- DevOps / CI/CD / MLOps (niveau infra)- Architecture distribuée
Data Analyst	Fait parler les données ; analyse, interprète et restitue les insights pour aider à la prise de décision.	- Collecte et nettoyage- Analyses statistiques- Création de dashboards & KPIs- Datavisualisation- Recommandations business	- SQL, Python/R- Statistiques descriptives & inférentielles- DataViz : Power BI, Tableau, Qlik- Communication & storytelling- Connaissance métier
Data Scientist	Construit des modèles prédictifs, explore les données, conçoit des algorithmes avancés pour générer de la valeur.	- Exploration & préparation de données- Modélisation ML & Deep Learning- Expérimentation & optimisation- Participation à l'industrialisation- Interprétation des résultats & recommandations	- Python / R- Machine Learning, Deep Learning- TensorFlow, PyTorch, Scikit-learn- Statistiques avancées, mathématiques- Big Data (Spark), Feature engineering

Métiers de la data

Métier	Rôle	Missions clés	Compétences clés
ML Engineer	Industrialise, déploie et optimise les modèles ML ; assure leur performance en production (MLOps).	- Déploiement de modèles (API, containers)- Mise en place pipelines ML (training / serving)- Monitoring des modèles (drift, performance)- Optimisation temps réel & scalabilité- Automatisation CI/CD ML	- Python, Scala- MLflow, Airflow, Kubeflow- Docker, Kubernetes- Cloud (AWS/GCP/Azure)- MLOps, DevOps appliqué au ML- Connaissances ML avancées
AI Engineer	Développe et intègre des solutions d'IA complètes (NLP, vision, modèles avancés) dans des applications opérationnelles.	- Conception & entraînement de modèles IA- Développement applicatif (IA embarquée, APIs)- Intégration logiciel + optimisation performance- Tests, évaluation, sécurité IA- Production de solutions IA end-to-end	- Python, C++ (parfois)- IA appliquée : NLP, CV, LLMs- Frameworks IA : TensorFlow, PyTorch- Software engineering & optimisation- Cloud & micro-services- Connaissances ML + architecture logicielle



CHAÎNE DE VALEUR DATA

CHAÎNE DE VALEUR DATA & IA

1. COLLECTE • STOCKAGE • INFRASTRUCTURES

DATA ENGINEER

- Construit les pipelines
- Gère data lakes
- Prépare les données
- Assure qualité & prod

Alimenté →
les phases d'analyse & ML

DATA ANALYST

- Analyse & KPIs
- Data visualisation
- Données enrichies

DATA SCIENTIST

- Modèles predictifs
- Deep learning
- Feature engineering

2. ANALYSE • EXPLORATION • MODÉLISATION

ML ENGINEER

- Déploie les modèles
- CI/CD ML pipelines
- Monitoring avancés

Données enrichies,
modèles prototypes

3. INDUSTRIALISATION • INTÉGRATION • MLOPS

AI ENGINEER

- Solutions IA end-to-end
- APIs, microservices
- NLP, Optimization IA

Modèles robustes,
scalables

4. SOLUTIONS IA • INTÉGRATION LOGICIELLE

Applications IA

opérationnelles

Cartographe des Métiers

DataOps - Présentation